


1. 证明: 点 (u, v) 到一条线 (a, b, c) 的距离为: $|au + bv + c|$, 这里 $a^2 + b^2 = 1$ (15分)



设点 $P(x_0, y_0)$ 和直线 $l(a, b, c)$ 的距离为点 P 到直线 l 的垂线段的长.

设点 P 到直线 l 的垂线为 l' , 垂足为 Q .

$$Ax + By + C = 0$$

$$Ax + C = -By$$

$$y = -\frac{A}{B}x - \frac{C}{B} \quad (1)$$

$\therefore l$ 的斜率为 $-\frac{A}{B}$.

$\because l \perp l' \therefore l'$ 斜率为 $\frac{B}{A}$.

$\therefore l'$ 方程为 $y - y_0 = \frac{B}{A}(x - x_0) \quad (2)$

将(1)代入(2)

$$-\frac{A}{B}x - \frac{C}{B} - y_0 = \frac{B}{A}(x - x_0)$$

$$-\frac{A}{B}x - \frac{C}{B} - y_0 = \frac{B}{A}x - \frac{B}{A}x_0$$

$$-\frac{C}{B} - y_0 + \frac{B}{A}x_0 = (\frac{B}{A} + \frac{A}{B})x$$

$$x = \frac{-\frac{C}{B} - y_0 + \frac{B}{A}x_0}{\frac{B^2 + A^2}{AB}}$$

$$x = \frac{-AB y_0 + B^2 x_0 - AC}{A^2 + B^2}$$

$$(1) \frac{A}{B}x = -\frac{C}{B} - y$$

$$x = -\frac{C}{A} - \frac{B}{A}y \quad (3)$$

将(3)代入(2)

$$y - y_0 = \frac{B}{A}(-\frac{C}{A} - \frac{B}{A}y - x_0)$$

$$y - y_0 = -\frac{BC}{A^2} - \frac{B^2}{A^2}y - \frac{B}{A}x_0$$

$$y + \frac{B^2}{A^2}y = -\frac{BC}{A^2} - \frac{B}{A}x_0 + y_0$$

$$(1 + \frac{B^2}{A^2})y = -\frac{BC}{A^2} - \frac{AB}{A^2}x_0 + \frac{A^2 y_0}{A^2}$$

$$(\frac{A^2 + B^2}{A^2})y = -\frac{BC}{A^2} - \frac{AB}{A^2}x_0 + \frac{A^2 y_0}{A^2}$$

$$y = \frac{A^2 y_0 - AB x_0 - BC}{A^2 + B^2}$$

\therefore 点 Q 坐标 $(\frac{B^2 x_0 - AB y_0 - AC}{A^2 + B^2}, \frac{A^2 y_0 - AB x_0 - BC}{A^2 + B^2})$

$$|PQ|^2 = (\frac{B^2 x_0 - AB y_0 - AC}{A^2 + B^2} - x_0)^2 + (\frac{A^2 y_0 - AB x_0 - BC}{A^2 + B^2} - y_0)^2$$

$$= (\frac{-A^2 x_0 - AB y_0 - AC}{A^2 + B^2})^2 + (\frac{-B^2 y_0 - AB x_0 - BC}{A^2 + B^2})^2$$

$$= \frac{A^2 (Ax_0 + By_0 + C)^2 + B^2 (By_0 + Ax_0 + C)^2}{(A^2 + B^2)^2}$$

$$= \frac{(Ax_0 + By_0 + C)^2}{A^2 + B^2}$$

$$\therefore |PQ| = \frac{|Ax_0 + By_0 + C|}{\sqrt{A^2 + B^2}}$$

$$\because A^2 + B^2 = 1, P(u, v),$$

$$\therefore d = |PQ| = |Au + Bv + c| \quad \#$$

2. 简述EM算法的基本原理和流程 (以高斯混合模型求解为例) (15分)

EM算法的基本原理：在概率模型中寻找最大似然估计或最大后验估计的算法。
其中，此概率模型依赖于无法观测的隐性变量

以高斯混合模型求解为例，现已知 $\left\{ \begin{array}{l} \text{各个类别的分布模型} \\ \text{采样数据} \end{array} \right.$

，通过EM算法求得 $\left\{ \begin{array}{l} \text{每采样数据所属类别} \\ \text{各个模型参数} (\mu, \Sigma, \pi) \text{ 的权重 (选择模型的先验概率)} \end{array} \right.$ μ 为均值， Σ 为方差， π 为高斯分布

而每采样数据的所属类别为隐变量，EM算法可用于解数据缺失的参数估计问题。

E-step：计算期望E，利用对隐变量的现有估计值，计算其最大似然估计值

M-step：最大化M，通过最大化在E-step中的最大似然估计值计算各参数值。
此参数值会用于下一个E-step。

E-step

已知样本集 $Y = (y_1, y_2, \dots, y_T)$ ，引入隐变量 $\gamma_{t,k}$ (表示样本 y_t 属于第 k 个模型)，
设总计有 M 个模型 (M 个类)， T 个样本

此时完整数据为 $(y_t, \gamma_{t,1}, \gamma_{t,2}, \dots, \gamma_{t,M})$ ， $t=1, 2, T$

若 y_t 属于第1个模型，则 $\gamma_{t,1} = 1$ ， $\gamma_{t,2} = \gamma_{t,3} = \dots = \gamma_{t,M} = 0$ ， $(y_t = 1, 0, \dots, 0)$

完全数据的似然函数 $p(y, \gamma | \mu, \Sigma, \pi) = \prod_{t=1}^T p(y_t, \gamma_{t,1}, \dots, \gamma_{t,M} | \mu, \Sigma, \pi)$

$N(y_t | \mu_k, \Sigma_k)$ 为第 k 个高斯模型的概率密度函数。

\Rightarrow 选定第 k 个模型后，模型产生 y_t 的概率。

$$\begin{aligned} &= \prod_{t=1}^T \prod_{k=1}^M (\pi_k N(y_t | \mu_k, \Sigma_k))^{\gamma_{t,k}} \\ &= \prod_{k=1}^M \pi_k^{\sum_{t=1}^T \gamma_{t,k}} \prod_{t=1}^T (N(y_t | \mu_k, \Sigma_k))^{\gamma_{t,k}} \end{aligned}$$

完全数据的对数似然函数

$$\ln p(y, \gamma | \mu, \Sigma, \pi)$$

目标：寻找 (μ_*, Σ_*, π_*) ，
使 $\ln p(y, \gamma | \mu, \Sigma, \pi)$ 最大

$$= \sum_{k=1}^M \left(\sum_{t=1}^T \gamma_{t,k} \right) \ln \pi_k + \sum_{t=1}^T \gamma_{t,k} \left(-\ln(2\pi) - \frac{1}{2} \ln |\Sigma_k| - \frac{1}{2} (y_t - \mu_k)^T (\Sigma_k)^{-1} (y_t - \mu_k) \right)$$

\therefore 隐变量 $\gamma_{t,k}$ 未知

\therefore 先给定起始参数 μ_0, Σ_0, π_0 ，或第 i 次迭代参数 μ_i, Σ_i, π_i ，对 γ 进行估计

最大化Q函数:

$$Q(\mu, \Sigma, \pi, \mu_i, \Sigma_i, \pi_i) = E_{\sigma} [\ln p(y, \sigma | \mu, \Sigma, \pi) | \underline{Y, \mu_i, \Sigma_i, \pi_i}]$$
$$= \sum_{k=1}^M \left(\sum_{t=1}^T E(\sigma_{t,k} | y_t, \mu_i, \Sigma_i, \pi_i) \ln \pi_k + \sum_{t=1}^T E(\sigma_{t,k} | y_t, \mu_i, \Sigma_i, \pi_i) (-\ln(2\pi)) - \frac{1}{2} \ln |\pi_k| \right. \\ \left. - \frac{1}{2} (y_t - \mu_t)^T (\Sigma_t)^{-1} (y_t - \mu_t) \right)$$

隐变量的期望值估计

↑ 前提

$$E(\sigma_{t,k} | y_t, \mu_i, \Sigma_i, \pi_i) = P(\sigma_{t,k} = 1 | y_t, \mu_i, \Sigma_i, \pi_i)$$

$$= \frac{\pi_{i,k} N(y_t; \mu_{i,k}, \Sigma_{i,k})}{\sum_{k=1}^M \pi_{i,k} N(y_t; \mu_{i,k}, \Sigma_{i,k})}$$

将 $E(\sigma_{t,k} | y_t, \mu_i, \Sigma_i, \pi_i)$ 的值代入Q函数, 此时Q函数无隐变量, 可最大化Q函数.

M-step

$$\mu_{i+1}, \Sigma_{i+1}, \pi_{i+1} = \arg \max Q(\mu, \Sigma, \pi, \mu_i, \Sigma_i, \pi_i)$$

对Q函数求导, 其导数为0, 可得:

$$\mu_{i+1,k} = \frac{\sum_{t=1}^T E(\sigma_{t,k} | y_t, \mu_i, \Sigma_i, \pi_i) y_t}{E(\sigma_{t,k} | y_t, \mu_i, \Sigma_i, \pi_i)} \quad k=1, 2, \dots, M$$

$$\Sigma_{i+1,k} = \frac{\sum_{t=1}^T E(\sigma_{t,k} | y_t, \mu_i, \Sigma_i, \pi_i) (y_t - \mu_{i,k})^2}{E(\sigma_{t,k} | y_t, \mu_i, \Sigma_i, \pi_i)} \quad k=1, 2, \dots, M$$

$$\pi_{i+1,k} = \frac{E(\sigma_{t,k} | y_t, \mu_i, \Sigma_i, \pi_i)}{M} \quad k=1, 2, \dots, M$$

3. 用伪代码写出Mean-shift的算法流程（以图像分割为例），并分析影响算法性能的主要因素。（15分）

图像分割 \Rightarrow 对图像中每个像素点给定一个类别的标签

图像特征点可提取至少5维特征，即 (x, y, R, G, B) 。RGB为非均匀颜色空间，因此我们可以选择转化为 (x, y, L, U, V) 来保证颜色的均匀性。

Mean shift 算法会寻找概率密度最大的点。由于不同的点最终会收敛于不同的峰值，因此这些点会生成一类，图像分割的任务完成。

执行过程：

- ① 迭代空间构建，用 (x, y, R, G, B) 和不同的窗口半径构成5维空间球体，此球体以点 P 为圆心 $(x_p, y_p, R_p, G_p, B_p)$ 。
- ② 求所有在这个球体空间内的点相对中心点 P 的色彩向量之和 (W) ，并将点 P 移至向量 W 的终点，此点作为新中心点 1 。重复步骤1直到中心点 P_n 不再移动。
- ③ 让输出图像对应的初始点 P 的色彩值更新为本轮迭代终点 P_n 的色彩值。
- ④ 对输入图像的每点都依次执行步骤1, 2, 3，完成均值漂移滤波。

Mean Shift 聚类流程：

- ① 在未标记的数据点中随机选择一个点作为中心点。
- ② 找出所有离中心点距离窗口半径之内的所有点，记为集合 M ，这些点为簇 c 。球内点属于这个类的概率加1。
- ③ 计算从中心点开始到集合 M 所有点的向量，并相加，得到向量 $shift$ 。
- ④ 中心点沿着 $shift$ 方向移动。
- ⑤ 重复步骤②, ③, ④，直到 $shift$ 的大小非常小，得新的中心点。
- ⑥ 若簇 c 的中心点与其他簇的中心点距离小于阈值，则合并为一类，否则 c 为新类。

影响算法性能的主要因素：

- ① 特征子的选取
- ② 窗口半径的大小

伪代码

Input: I , Picture features (x, y, R, G, B)
 Φ , Kernel
 B , Bandwidth (窗口半径)
 t , threshold.

Output: Λ , Picture Segmentation
 (x, y, k) ,
 $k \in \{N_1, N_2, \dots, N_k\}$

```
i = 0
do
   $C_i = (I / \Lambda) \text{ (random)}$   $\Rightarrow$  随机采样部分样本来降低复杂度.
  do
    for  $\{P_i\}$  in sphere of  $C$  with bandwidth  $B$  do
       $\vec{S} = \sum f(P_i, C, \Phi)$   $\Rightarrow \vec{S}$ : 漂移向量.
       $c(P_i, i) = c(P_i, i) + 1$ 
    end for
     $P = P + \vec{S}$   $\Rightarrow \vec{S}$ : 向量
  while  $\|\vec{S}\| > t$ ,  $\Rightarrow$  移动距离 > 阈值.
  for  $k \in \{1, 2, \dots, j-1\}$  do
    if  $\|C_k - C_i\| < B$  then
      merge( $C_k, C_i$ )
    end if.
  end for
while not  $I / \Lambda = \emptyset$ 
return  $\Lambda$ 
```